REPORTE DE PRÁCTICA: INTELIGENCIA ARTIFICIAL

Materia: Inteligencia Artificial

Alumno: Manuel López

---

1. INTRODUCCIÓN Y OBJETIVO

En esta práctica se llevó a cabo la adaptación de un código base de redes neuronales escrito en PyTorch (orientado originalmente a otro conjunto de datos) para aplicarlo a una nueva base de datos en formato `.csv`. El objetivo principal consiste en entrenar y evaluar un modelo de regresión capaz de predecir un valor numérico continuo empleando características estructuradas.

2. DESCRIPCIÓN DE LA BASE DE DATOS (AUTOMPG.CSV)

Se utilizó la base de datos **Auto MPG**, la cual cuenta con 398 registros de especificaciones técnicas de automóviles. Para realizar la predicción, se seleccionaron cinco variables predictoras numéricas y una columna objetivo central.

Columna del CSV	Tipo de Dato	Uso en el Modelo
`displacement`	Numérica	Variable de entrada (Desplazamiento)
`cylinders`	Numérica	Variable de entrada (Cilindros)
`weight`	Numérica	Variable de entrada (Peso del auto)
`acceleration`	Numérica	Variable de entrada (Aceleración)
`model_year`	Numérica	Variable de entrada (Año del modelo)
`mpg`	Numérica	Columna Objetivo (Y - Millas por galón)

3. ARQUITECTURA DE LA RED NEURONAL

El modelo se estructuró mediante capas densas secuenciales con la siguiente arquitectura:

- **Capa de entrada:** 5 neuronas (correspondientes a las variables predictoras normalizadas con `StandardScaler`).
- **Capa oculta 1:** 16 neuronas con función de activación `ReLU`.
- **Capa oculta 2:** 8 neuronas con función de activación `ReLU`.
- **Capa de salida:** 1 neurona lineal (sin función de activación, ideal para regresión).

4. EXPERIMENTACIÓN Y ANÁLISIS DE ÉPOCAS

Se realizaron pruebas modificando el número de épocas de entrenamiento para observar el comportamiento del Error Absoluto Medio (MAE) en los datos de prueba y comprobar el fenómeno de sobreajuste:

Épocas	MAE Obtenido	Observación / Comportamiento
100 Épocas	6.0	Subajuste (Underfitting): Faltó tiempo de entrenamiento para reducir el error.
600 Épocas	1.8	Punto óptimo (Sweet Spot): Mejor desempeño y generalización del modelo.
1000 Épocas	1.9	Inicios de sobreajuste leve por exceso de iteraciones.
2000 Épocas	2.2	Sobreajuste (Overfitting): La red comienza a memorizar ruido y empeora en test.

5. CONCLUSIONES

La adaptación del código base al archivo `AUTOMPG.csv` fue exitosa, logrando un coeficiente de determinación R^2 de 0.851. Asimismo, se comprobó experimentalmente que aumentar desmedidamente las épocas degrada ligeramente la capacidad predictiva del modelo debido al sobreajuste, validando los conceptos teóricos de la materia.